

Der vorliegende Datensatz `data_attrition_filtered` umfasst verschiedene spezifische Charakteristiken von Mitarbeitenden in einem Unternehmen. Ein Einblick in die Struktur des Datensatzes ist durch die folgende Darstellung gegeben:

```
Rows: 1,470
Columns: 7
$ job_level          <int> 2, 2, 1, 1, 1, 1, 1, 1, 3, 2, 1, 2, 1, 1, 1~
$ job_role           <fct> Sales_Executive, Research_Scientist, Labora~
$ total_working_years <int> 8, 10, 7, 8, 6, 8, 12, 1, 10, 17, 6, 10, 5,~
$ years_since_last_promotion <int> 0, 1, 0, 3, 2, 3, 0, 0, 1, 7, 0, 0, 4, 1, 0~
$ years_with_curr_manager <int> 5, 7, 0, 0, 2, 6, 0, 0, 8, 7, 3, 8, 3, 2, 3~
$ attrition          <fct> Yes, No, Yes, No, No, No, No, No, No, No, N~
$ monthly_income     <int> 5993, 5130, 2090, 2909, 3468, 3068, 2670, 2~
```

Aufgabe 1 (6+6 = 12 Punkte)

Aufgabe 1.1 (4+2 = 6 Punkte). Im Zuge einer ersten Analyse des Datensatzes wird der folgende Code ausgeführt:

```
1 data_attrition_filtered %>%
2   group_by(job_role) %>%
3   summarise(n = n(),
4             mean_inc = mean(monthly_income)) %>%
5   arrange(desc(mean_inc))
```

1. Erkläre, wie die gegebene Anreihung an R-Funktionen die übergebenen Daten `data_attrition_filtered` sequentiell verarbeitet und beschreibe hierbei auch den zu erwartenden Output.
2. Wie muss das gegebene Code-Snippet angepasst werden, um neben der Job-Rolle auch bezüglich der Variable `attrition` zu gruppieren? Nenne die zu ändernde Code-Zeile und passe diese entsprechend an.

Aufgabe 1.2 (2+2+2 = 6 Punkte). Nun wird ein Lineares Regressionsmodell geschätzt.

1. Für die Schätzung der Parameter wird folgendes Code-Snippet verwendet:

```
data_num <- data_attrition_filtered %>%
  select_if(is.numeric)

lm_fit <- linear_reg() %>%
  fit(data = data_num,
      formula = monthly_income~.)
```


Schreibe die Modellgleichung für das oben geschätzte Modell auf.

2. Welches Problem tritt beim Schätzen der Modellparameter auf, wenn zwei Variablen perfekt miteinander korrelieren?
3. Erkläre kurz das Vorgehen wie grafisch geprüft werden kann, ob das Modell von Heteroskedastizität betroffen ist.

Aufgabe 2 (4+6+2 = 12 Punkte)

Nach der Erstellung des linearen Modells werden nun verschiedene Regressionsbäume für die Zielvariable `monthly_income` geschätzt.

Aufgabe 2.1 (4 Punkte). Gegeben sei folgender Featurespace, in welchem die Vorhersagewerte eines Baumes für die Variable `monthly_income` durch verschiedene Werte der Variable `job_level` dargestellt sind.



Skizziere einen dazugehörigen Binärbaum. Gebe hierbei für jeden Split die Splittingvariable und die Entscheidungsregel mit dazugehörigen Schwellenwert an und in jedem Blattknoten den geschätzten Wert.

Aufgabe 2.2 (3+3 = 6 Punkte). Es wird nun ein neuer Regressionsbaum für das Modellieren der Variable `monthly_income` geschätzt.

1. Nach dem Schätzen ergibt sich folgende `cp`-Tabelle mit fehlenden Werten `a`, `b` und `c`. Berechne die fehlenden Werte.

	CP	nsplit	rel error	xerror	xstd
1	0.70245809	0	a	1.00153499	0.050672753
2	b	1	0.29754191	0.29931618	0.013685864
3	0.05629602	2	0.14545523	0.14606245	0.006133442
4	0.01694378	3	0.08915921	0.08988845	0.004899952
5	0.01108238	4	c	0.07429344	0.004100580
6	0.01000000	5	0.06113306	0.06874217	0.003803068

2. Der auf Trainingsdaten geschätzte Baum soll nun auf den Testdaten evaluiert werden. Angenommen die Testdaten sind in einem Objekt `data_test` gespeichert und der geschätzte Baum in einem `decision_tree` Objekt namens `tree_fit`. Gebe den R Code an, um die Metrik `RMSE` für den in der Aufgabenstellung spezifizierten Baum auf Basis der Testdaten zu berechnen.

Aufgabe 2.3 (2 Punkte). Gegeben sei folgende Aussage:

Ein Bagging Tree Modell eignet sich im Vergleich zu einem Random Forest Modell besser für Regressionsaufgaben, da bei Random Forest Modellen in jedem Split eines Baumes nicht alle Variablen berücksichtigt werden.

Beurteile den Wahrheitsgehalt dieser Aussage und begründe die Entscheidung.

Aufgabe 3 (7+5 = 12 Punkte)

Aufgabe 3.1 (3+2+2 = 7 Punkte).

1. Beim Trainieren von Neuronale Netzen wird zur Anpassung der Parameter das Verfahren Gradient Descent verwendet. Erkläre kurz die Idee hinter diesem Verfahren. Gehe hierbei auf folgende Punkte ein:
 - i) Rolle der Loss-Funktion.
 - ii) Initialisierung der Gewichte.
 - iii) Einfluss der Schrittweite.
2. Beim Anpassen der Parameter kann der Exploding-Gradient Effekt auftreten. Definiere und beschreibe diesen Effekt.
3. Zur effizienten Berechnung der Gradienten wird der Backpropagation Algorithmus verwendet. Warum ist dieser effizienter im Vergleich zur Berechnung der Gradienten ohne Backpropagation?

Aufgabe 3.2 (2+1+2 = 5 Punkte). Folgendes Code-Snippet wurde verwendet um ein Neuronales Netz mit Zielvariable `monthly_income` zu trainieren:

```
nnet_spec <- mlp(epochs = 300,
  hidden_units = c(64,32),
  learn_rate = 0.025,
  activation = c("relu","relu"),
  penalty = 0.01,
  mode = "regression"
) %>%
set_engine(engine = "brulee",
  verbose = FALSE,
  optimizer = "SGD",
  stop_iter = 15
)
```

1. Es sei bekannt, dass das die transformierten Trainingsdaten 16 Spalten (inkl. Zielvariable) enthalten. Wie viele Parameter besitzt dann das spezifizierte Neuronale Netz?
2. Wurde das spezifizierte Modell penalisiert? Begründe die Entscheidung.
3. Das trainierte Neuronale Netz wurde dann auf den Test Daten evaluiert, indem ein lineares Modell geschätzt wurde, bei welchem die Vorhersagen des Neuronale Netzes als erklärende Variable und die tatsächlichen Werte als unabhängige Variable verwendet wurden. Ein Teil der Modellzusammenfassung ist folgend zu sehen.

...

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	155.01290	110.38655	1.404	0.161
pred_nn	0.99483	0.01474	67.490	<2e-16 ***

...

Sind die Vorhersagen des Neuronale Netzes auf Basis der Testdaten statistische Signifikant? Begründe die Entscheidung.

Für die folgenden beiden Aufgaben (Aufgabe 4 und Aufgabe 5) wird ein neuer Teildatensatz `data_attrition_filtered_new` verwendet, welcher folgende Struktur besitzt:

Rows: 1,470

Columns: 6

```
$ Age                <int> 41, 49, 37, 33, 27, 32, 59, 30, 38, 36, 35, 29~
$ EnvironmentSatisfaction <int> 2, 3, 4, 4, 1, 4, 3, 4, 4, 3, 1, 4, 1, 2, 3, 2~
$ JobInvolvement      <int> 3, 2, 2, 3, 3, 3, 4, 3, 2, 3, 4, 2, 3, 3, 2, 4~
$ JobSatisfaction     <int> 4, 2, 3, 3, 2, 4, 1, 3, 3, 3, 2, 3, 3, 4, 3, 1~
$ YearsInCurrentRole  <int> 4, 7, 0, 7, 2, 7, 0, 0, 7, 7, 4, 5, 2, 2, 2, 9~
$ Attrition           <fct> Positive, Negative, Positive, Negative, Negati~
```

Aufgabe 4 (5+7 = 12 Punkte)

Aufgabe 4.1 (2+3 = 5 Punkte). Für die Variable `Attrition`, welche Beschreibt, ob ein Angestellter oder eine Angestellte das Unternehmen verlässt ("Positive") oder nicht ("Negative"), wird nun ein logistisches Regressionsmodell auf Trainingsdaten geschätzt. Folgende Übersicht über die Geschätzten Parameter resultiert aus diesem Modell:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	3.59203	0.58562	6.134	8.59e-10
Age	-0.05775	a	-5.303	1.14e-07
EnvironmentSatisfaction	-0.26347	0.07900	-3.335	0.000853
JobInvolvement	-0.52651	0.11906	-4.422	9.76e-06
JobSatisfaction	-0.28869	0.07885	b	0.000251
YearsInCurrentRole	-0.11441	0.02975	-3.845	0.000120

1. Berechne die fehlenden Werte *a* und *b*.
2. Wie verändern sich die Odds des Modells durch das Erhöhen der Variable `JobInvolvement` um eine Einheit unter der Annahme, dass alle anderen Variablen gleich bleiben?

Aufgabe 4.2 (3+4 = 7 Punkte). Für das Modell aus Aufgabe 4.1 werden nun auf Basis der Testdaten zwei Konfusionsmatrizen erzeugt. Über den jeweiligen Matrizen steht der Schwellenwert, welcher zur Berechnung der jeweiligen Konfusionsmatrix verwendet wurde.

		Schwellenwert = 0.5		Schwellenwert = 0.15	
Truth	Positive	5	61	41	25
	Negative	1	301	105	197
		Positive Negative Prediction		Positive Negative Prediction	

1. Welcher der beiden Schwellenwerte sollte verwendet werden, um eine möglichst hohe Accuracy zu erreichen? Begründe die Aussage.
2. Welcher der beiden Schwellenwerte sollte gewählt werden, um eine möglichst hohe Sensitivität bei der Erkennung von Mitarbeitenden zu erreichen, die das Unternehmen tatsächlich verlassen möchten?

Aufgabe 5 (12 Punkte)

Aufgabe 5.1 (2+6+4 = 12 Punkte). Auf den Datensatz `data_attrition_filtered` soll nun ein Hierarchisches Clusterverfahren angewendet werden.

1. In einem ersten Schritt wird für den gegebenen Datensatz die Gower Distanz berechnet. Erkläre warum wir für den gegebenen Datensatz nicht ohne Weiteres die Manhattan Distanz verwenden können.
2. Nun sei folgender Auszug aus der Distanzmatrix gegeben:

```
...
Dissimilarities :
      1      2      3      4
2 0.732
3 0.417 0.626
4 0.566 0.366 0.597
5 0.608 0.483 0.749 0.355
...
```

Führe für diesen Auszug die ersten zwei Schritte des Single-Linkage Verfahrens durch. Gehe hierbei wie folgt vor:

- Gib nach jedem Schritt die resultierenden Distanzen in einer neuen Distanzmatrix an.
 - Gib nach dem zweiten Schritt die finalen Cluster an.
3. Folgendes Code-Snippet wurde verwendet, um die ersten vier Zeilen des "merge" Attributs eines "hclust" Objekts auszugeben.

```
1 data_attrition_filtered_new %>%
2   mutate_if(is.numeric, scale) %>%
3   fastDummies::dummy_cols() %>%
4   select(-Attrition) %>%
5   daisy(metric = "gower") %>%
6   hclust(method = "complete") %>%
7   pluck("merge") %>%
8   head(4)
```

- i. Erkläre den Zweck und die Funktionsweise der in den Code-Zeilen 2-4 angewendeten Funktionen.
- ii. Identifiziere die Codezeile, welche abgeändert werden muss, um das Single-Linkage Verfahren anzuwenden. Gebe anschließend die entsprechende abgeänderte Code-Zeile an.