

## Aufgabenstellung

Der vorliegende Datensatz umfasst verschiedene spezifische Charakteristiken von insgesamt  $K = 4177$  Abalonen (Seeohren, siehe Figure: 1). Folgende Übersicht der Variablen und erste statistische Kennzahlen dienen als Grundlage für weitere Fragestellungen:

| Variable       | Beschreibung                      | Häufigkeit | Mittelwert | Min    | Max    |
|----------------|-----------------------------------|------------|------------|--------|--------|
| sex            | Geschlecht:                       |            |            |        |        |
|                | M='Männlich'                      | 1528       |            |        |        |
|                | F='Weiblich'                      | 1307       |            |        |        |
|                | I='Infant'                        | 1342       |            |        |        |
| length         | Längstes Schalenmaß [in mm]       |            | 0.524      | 0.075  | 0.815  |
| diameter       | Zu length                         |            |            |        |        |
|                | senkrecht liegende Seite [in mm]  |            | 0.4079     | 0.0550 | 0.6500 |
| height         | Höhe (insgesamt) [in mm]          |            | 0.1395     | 0      | 1.13   |
| whole_weight   | Gesamtgewicht [in g]              |            | 0.8287     | 0.0020 | 2.8255 |
| shucked_weight | Gewicht des Fleisches [in g]      |            | 0.3594     | 0.0010 | 1.4880 |
| viscera_weight | Gewicht der inneren Organe [in g] |            | 0.1806     | 0.0005 | 0.7600 |
| shell_weight   | Gewicht der Schale                |            |            |        |        |
|                | nach dem Trocknen [in g]          |            | 0.2388     | 0.0015 | 1.0050 |
| rings          | Anzahl der Ringe in der Schale    |            | 9.9340     | 1      | 29     |




Figure 1: Bild einer Abalone, Quelle: [\(Shutterstock\)](#)

**Aufgabe 1 (12 Punkte (3+4+2+3))**

Da das bestimmen des Gewichts der Schalen durch die Trocknung sehr zeitintensiv ist, kann man dieses alternativ auch durch eine Multiple Lineare Regression (MLR) modellieren. Folgende Übersicht für ein bereits geschätztes MLR-Modell wurde mithilfe der `lm.beta` und `summary` Funktion erzeugt:

```
...
Coefficients:
              Estimate Standardized Std. Error t value Pr(>|t|)
(Intercept)  -4.285e-02           NA   3.976e-03 -10.779  < 2e-16 ***
sexI          1.709e-03    5.735e-03   1.401e-03   1.220   0.2226
sexM        -9.841e-05   -3.407e-04   1.139e-03  -0.086   0.9312
length      -6.076e-02   -5.243e-02   2.474e-02  -2.456   0.0141 *
diameter     1.893e-01    1.350e-01   3.048e-02   6.210   5.8e-10 ***
height       3.311e-01    9.157e-02   3.088e-02  10.723  < 2e-16 ***
whole_weight  5.027e-01    1.770e+00   6.135e-03  81.936  < 2e-16 ***
shucked_weight -4.397e-01  -7.005e-01   8.885e-03 -49.486  < 2e-16 ***
viscera_weight -3.815e-01  -3.002e-01   1.669e-02 -22.853  < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.02998 on 4166 degrees of freedom
Multiple R-squared:  0.9537,    Adjusted R-squared:  0.9536
F-statistic: 1.072e+04 on 8 and 4166 DF,  p-value: < 2.2e-16
...
```


1. Stellen Sie für das obige Modell die Modellgleichung mit eingesetzten Zahlen auf.

2. Der folgende Sachverhalt bezieht sich auf die Variable **diameter** (Durchmesser) und dem marginalen Effekt auf das Schalengewicht.

- i) Ist der Effekt positiv oder negativ? Begründen Sie Ihre Aussage.
- ii) Entspricht dies den Erwartungen? Begründen Sie Ihre Aussage.
- iii) Wie hoch ist die erwartete Gewichtsänderung, wenn die Variable **diameter** um eine Einheit erhöht wird, während alle anderen Variablen konstant bleiben?

3. Welche Variable im obigen Modell hat den kleinsten Einfluss auf die Zielvariable **shell\_weight**? Begründen Sie ihre Aussage.

4. Beim Überprüfen der Modellannahmen des MLR Modells fällt Ihnen folgende Grafik besonders auf.



- i) Welche Modellannahme wird hier geprüft?
- ii) Entscheiden Sie mit Begründung und Bezug auf die Grafik, ob die Modellannahme erfüllt ist.

## Aufgabe 2 (12 Punkte (3+3+3+3))

Nach der Erstellung des linearen Modells wird nun ein Regressionsbaum für die Zielvariable `shell_weight` erstellt. Ein Ausschnitt des Outputs des Modells ist gegeben durch:

```
...
node), split, n, deviance, yval
  * denotes terminal node

1) root 4177 80.919950 0.23883090
  2) length< 0.5325 1975 9.089090 0.12564810
    4) diameter< 0.3375 942 1.267552 0.06961518 *
    5) diameter>=0.3375 1033 2.166908 0.17674490 *
  3) length>=0.5325 2202 23.838200 0.34034580
    6) diameter< 0.4925 1343 4.691571 0.28469060 *
    7) diameter>=0.4925 859 8.482839 0.42735970 *
...
```

1. Gegeben Sei folgende Ausprägung:


|                | value  |
|----------------|--------|
| sex            | M      |
| length         | 0.455  |
| diameter       | 0.365  |
| height         | 0.095  |
| whole_weight   | 0.5140 |
| shucked_weight | 0.2245 |
| viscera_weight | 0.1010 |
| shell_weight   | 0.1500 |
| rings          | 15     |

Berechnen Sie für diese Ausprägung das durch den Regressionsbaum geschätzte Schalengewicht.

2. Berechnen Sie für den auf der vorherigen Seite erstellten Regressionsbaum den durch den zweiten Split erzeugten *Improvement Wert*.

3. Für den auf der vorherigen Seite erstellten Regressionsbaum wurde in keinem Split das Feature **height** verwendet. Warum ist dieses Feature im dargestellten Baum nicht auffindbar? Begründen Sie Ihre Aussage anhand des Recursive Binary Splitting Algorithmus.

4. Nach dem Trainieren eines weiteren Regressionsbaums wird mithilfe der `fancyRpartplot` Funktion ein Baumdiagramm (links) erzeugt. Daneben (rechts) finden Sie einen Feature-Space welcher das Baumdiagramm abbilden soll.



Entscheiden Sie unter Angabe der richtigen Begründung, ob die beiden abgebildeten Diagramme denselben Baum darstellen.

**Aufgabe 3 (12 Punkte (2+4+3+3))**

Als Erweiterung des linearen Modells in Aufgabe 1 soll nun der Einfluss der einzelnen Features auf die Zielvariable `shell_weight` mit Hilfe eines Multilayer Perceptron Netzes (MLP-Netzes) modelliert werden. Die Daten wurden für das Training des MLP-Modells bereits aufbereitet, sowie in Trainings- und Testdaten aufgeteilt. Betrachten Sie für die folgenden Teilaufgaben den untenstehenden Code, welcher verwendet wurde um das Modell zu spezifizieren und trainieren:

```
set.seed(123)
mlp_abalone_spec <- rec_abalone %>%
  brulee_mlp(data = data_train,
             hidden_units = c(18,18),
             learn_rate = 0.01,
             epochs = 200,
             stop_iter = 20,
             optimizer = "SGD"
             )
```

1. Wie viele Koeffizienten (Weights und Biases) enthält das oben spezifizierte Modell unter der Annahme dass die Dimension der Input Layer 9 und die Dimension der Output Layer 1 beträgt?

2. Welche Argumente in dem spezifizierten Modell können den Trainingsprozess beenden. Nennen sie die relevanten Argumente und beschreiben Sie inwiefern diese den Trainingsprozess beenden können.



3. Nach dem Trainieren des obigen MLP Modells wird dieses auf den Test Daten evaluiert. Hierbei wurde folgende Metrik berechnet:


```
value  
rmse 0.07138806
```

Interpretieren Sie diese Metrik und den Wert der Metrik am Sachverhalt.

4. Könnte man mit einem MLP Modell welches nur eine Hidden Layer hat einen kleineren RMSE auf den Testdaten erzielen? Begründen Sie Ihre Aussage.

**Aufgabe 4 (12 Punkte (2+3+3+4))**

Um die Erfassung von Infant Abalonen zu vereinfachen, wurde die Variable **sex** angepasst, so dass diese nur noch die Ausprägungen "A" für Adult und "I" für Infant enthält. Es soll nun eine Klassifizierung bezüglich der angepassten kategoriellen Variable **sex** mit Hilfe einer logistischen Regression durchgeführt werden. Für die Evaluation des logistischen Regressionsmodells wurden die untenstehende Confusion Matrix und ROC Kurve erstellt.




1. Wie viele Instanzen wurden laut der Confusion Matrix korrekt klassifiziert?

2. Wie hoch ist der Anteil der fälschlicherweise als Adult klassifizierten Beobachtungen an der Gesamtanzahl aller tatsächlichen Infant Abalonen?

3. Die folgende Teilaufgabe bezieht sich auf die Receiver-Operator Characteristic (ROC) Kurve der vorherigen Seite. Markieren Sie das einzelne Gitterfeld auf der Grafik der ROC Kurve, welches für das gegebene Modell sowohl die Sensitivität als auch die Spezifität simultan maximiert.
4. Beurteilen Sie die folgende Aussage auf Richtigkeit und begründen Sie Ihre Entscheidung.


„Falls ein beliebiges, binäres Klassifizierungsmodell eine Accuracy von 99.9% auf den Test Daten erreicht, ist es sehr gut geeignet beide Klassen korrekt vorherzusagen.“



### Aufgabe 5 (12 Punkte (3+3+3+3))

In den folgenden Teilaufgaben wurden aus dem `data_abalone` Datensatz die Variablen `length` und `whole_weight` extrahiert, normiert und in einem neuen Tibble `data_clust` gespeichert. Mit Hilfe der Clusteranalyse sollen Abalonen mit ähnlichen Eigenschaften geeignet gruppiert werden.


1. Erklären Sie die grundlegende Idee des Gower-Koeffizienten und argumentieren Sie, warum dieser für Datensätze mit gemischten Variablen gut geeignet ist.



2. Für drei konkrete Abalonen sei bekannt:

|      | <code>length</code> | <code>whole_weight</code> |
|------|---------------------|---------------------------|
| [1,] | -0.6993926          | -0.6377430                |
| [2,] | 0.1749304           | -0.1238653                |
| [3,] | -0.1997795          | -0.3349222                |

Berechnen Sie für die gegebenen Punkte die Euklidische Distanzen und entscheiden Sie basierend auf Ihrer Berechnung, welche der Ausprägungen bezüglich dieser Distanz jeweils am nächsten, bzw. am weitesten voneinander entfernt sind.



3. Es soll nun ein K-Means Modell unter Verwendung des Datensatzes `data_clust` trainiert werden. Ein Auszug des Datensatzes sieht folgend aus:

```
# A tibble: 2 x 2
  length whole_weight
  <dbl>         <dbl>
1 -0.574        -0.642
2 -1.45         -1.23
```

Geben Sie den R Code an, um ein K-means modell zu trainieren, welches alle Variablen des Datensatzes verwendet. Bei der Spezifikation des Modells soll die Anzahl der Cluster auf 4 gesetzt werden. *Hinweis: Sie müssen keine Libraries angeben und dürfen zur Umsetzung jede beliebige Funktion der `{tidyverse}`, `{tidyclust}`, `{tidymodels}` und `{stats}` Libraries verwenden.*

4. Erklären Sie die Idee hinter hierarchischen Clusterverfahren.