

Aufgabenstellungen!

Diesen Bogen erst nach Beginn der Bearbeitungszeit aufschlagen.

Der vorliegende Datensatz `data_attrition_filtered` umfasst verschiedene spezifische Charakteristiken von Mitarbeitenden in einem Unternehmen. Ein Einblick in die Struktur des Datensatzes ist durch die folgende Darstellung gegeben:

```
Rows: 1,470
Columns: 7
$ job_level      <int> 2, 2, 1, 1, 1, 1, 1, 1, 3, 2, 1, 2, 1, 1, 1~
$ job_role       <fct> Sales_Executive, Research_Scientist, Labora~
$ total_working_years <int> 8, 10, 7, 8, 6, 8, 12, 1, 10, 17, 6, 10, 5,~
$ years_since_last_promotion <int> 0, 1, 0, 3, 2, 3, 0, 0, 1, 7, 0, 0, 4, 1, 0~
$ years_with_curr_manager <int> 5, 7, 0, 0, 2, 6, 0, 0, 8, 7, 3, 8, 3, 2, 3~
$ attrition      <fct> Yes, No, Yes, No, No, No, No, No, No, N~
$ monthly_income <int> 5993, 5130, 2090, 2909, 3468, 3068, 2670, 2~
```

Aufgabe 1 (6+6 = 12 Punkte)

Aufgabe 1.1 (3+1+2 = 6 Punkte). Im Zuge einer ersten Analyse des Datensatzes wird der folgende Code ausgeführt:

```
1 data_attrition_filtered %>%
2   group_by(job_role) %>%
3   summarise('q75_work_years' = quantile(total_working_years,0.75)) %>%
4   arrange(q75_work_years)
```

1. Erkläre, wie die gegebene Anreihung an R-Funktionen die übergebenen Daten `data_attrition_filtered` sequentiell verarbeitet und beschreibe hierbei auch den zu erwartenden Output.
2. Beschreibe den zu erwartenden Output.
3. Wie muss das gegebene Code-Snippet angepasst werden, damit die Ergebnisse absteigend sortiert werden? Nenne die zu ändernde Code-Zeile und passe diese entsprechend an.

Aufgabe 1.2 (3+3 = 6 Punkte). Nun wird ein Lineares Regressionsmodell geschätzt.

1. Für die Schätzung der Parameter wird folgendes Code-Snippet verwendet:

```
lm_fit <- linear_reg() %>%
  fit(data = data_train, formula = monthly_income~job_role+job_level)
```

Wie wird die Variable `job_role` aufgrund der nominalen Skalierung im Zuge der Parameterschätzung angepasst, um den Einfluss der verschiedenen Ausprägungen zu berücksichtigen? Nenne ein mögliches Verfahren und beschreibe kurz den Ablauf.

2. Für ein weiteres lineares Regressionsmodell, welches bezüglich der Formel `job_level~job_role` geschätzt wird, sei Folgendes bekannt:

```
...
Residual standard error: 0.5507 on 1093 degrees of freedom
Multiple R-squared: 0.7576, Adjusted R-squared: 0.7558
F-statistic: 427 on 8 and 1093 DF, p-value: < 2.2e-16
...
```

Berechne auf Basis der gegebenen Informationen den Variance Inflation Factor der Variable `job_role` und entscheide, ob diese Variable von Multikollinearität betroffen ist.

Aufgabe 2 (4+6+2 = 12 Punkte)

Aufgabe 2.1 (2+3 = 5 Punkte). Es wird nun ein Regressionsbaum für das Vorhersagen der Variable `monthly_income` geschätzt.

1. Aus dem geschätzten Baum ergibt sich folgende Darstellung

`n= 299`


```
node), split, n, deviance, yval
* denotes terminal node
```

```
1) root 299 12240860000 7046.545
  2) job_role=Research_Scientist 217 318323200 3234.203
    4) total_working_years< 8.5 138 80539430 2768.783
      8) total_working_years< 1.5 20 8715632 1964.900 *
      9) total_working_years>=1.5 118 56708650 2905.034 *
    5) total_working_years>=8.5 79 155672600 4047.215 *
  3) job_role=Manager 82 422453100 17135.300
    6) total_working_years< 18 10 29857530 12692.200 *
    7) total_working_years>=18 72 167765400 17752.400 *
```

Wie viel würde, entsprechend dem geschätzten Modell, eine Research Scientist verdienen, falls diese bereits seit 10 Jahren im Betrieb arbeitet?

2. Der auf Trainingsdaten geschätzte Baum soll nun auf den Testdaten evaluiert werden. Angenommen, die Testdaten sind in einem Objekt `data_test` gespeichert und der geschätzte Baum in einem `decision_tree`-Objekt namens `tree_fit`. Gib den R-Code an, um die Metrik MAE für den in der Aufgabenstellung spezifizierten Baum auf Basis der Testdaten zu berechnen.

Aufgabe 2.2 (7 Punkte). Gegeben sei folgender Feature Space bestehend aus den Punkten $(x_i, y_i)_{i=1}^4 \in \{(1, 2), (1, 3), (2, 2), (4, 5)\}$




Um die Variable y durch x zu erklären, soll ein Regressionsbaum geschätzt werden. Berechne den CP-Wert, welcher sich durch das Teilen des Featurespaces im Punkt $x = 3$ ergibt.

Aufgabe 3 (5+7 = 12 Punkte)

Aufgabe 3.1 (2+1+2 = 5 Punkte). Folgendes Code-Snippet wurde verwendet um ein Neuronales Netz mit Zielvariable `monthly_income` zu trainieren:


```
nnet_spec <- mlp(epochs = 200,
  hidden_units = c(256,128,4),
  learn_rate = 0.03,
  activation = "relu",
  penalty = 0.01,
  mode = "regression"
) %>%
set_engine(engine = "brulee",
  verbose = FALSE,
  optimizer = "SGD",
  stop_iter = 15
)
```

1. Aus wie vielen Layern (inkl. Input- und Outputlayer) besteht das spezifizierte Modell?
2. Welche weitere Penalisierungsmöglichkeit neben der bereits bestehenden könnte man auf das spezifizierte Neuronale Netz anwenden?
3. Das trainierte Neuronale Netz wurde dann auf den Testdaten evaluiert, indem ein lineares Modell geschätzt wurde, bei welchem die Vorhersagen des Neuronalen Netzes als erklärende Variable und die tatsächlichen Werte als unabhängige Variable verwendet wurden. Die Ergebnisse dieser Regression wurden in folgendem Plot dargestellt.



Überschätzt oder unterschätzt das Neuronale Netz im Schnitt das Einkommen der Personen, welche mehr als 15.000 Geldeinheiten pro Monat verdienen? Begründe die Aussage!

Aufgabe 3.2 (2+4+1 = 7 Punkte). Für ein weiteres Neuronales Netz sei folgende grafische Darstellung gegeben:



1. Wie viele Parameter besitzt das gegebene Neuronale Netz?
2. Folgende Informationen sind bekannt

- $\omega_{B_1} = (\omega_{B_1, H_{1,1}} \quad \omega_{B_1, H_{1,2}}) = (0.5 \quad 0.5)$, $\omega_{I_1, H_1} = (\omega_{I_1, H_{1,1}} \quad \omega_{I_1, H_{1,2}}) = (0.25 \quad -0.5)$
- $\omega_{H_1, O_1} = (\omega_{H_{1,1}, O_1} \quad \omega_{H_{1,2}, O_1}) = (0.25 \quad -0.5)$, $\omega_{B_2} = -1$
- die Aktivierungsfunktion der ersten Hidden Layer ist ReLU

Berechne den Output $\hat{y}$ des Neuronalen Netzes für den Inputwert $x = 5$.

3. Durch das Anwenden welcher, aus der Vorlesung bekannter, Aktivierungsfunktion auf den Output kann der Bildbereich auf die Werte $[-1, 1]$ eingeschränkt werden?

Für die folgenden beiden Aufgaben (Aufgabe 4 und Aufgabe 5) wird ein neuer Teildatensatz `data_attrition_filtered_new` verwendet, welcher folgende Struktur besitzt:

Rows: 1,470

Columns: 6

```
$ Age                <int> 41, 49, 37, 33, 27, 32, 59, 30, 38, 36, 35, 29~
$ EnvironmentSatisfaction <int> 2, 3, 4, 4, 1, 4, 3, 4, 4, 3, 1, 4, 1, 2, 3, 2~
$ JobInvolvement      <int> 3, 2, 2, 3, 3, 3, 4, 3, 2, 3, 4, 2, 3, 3, 2, 4~
$ JobSatisfaction     <int> 4, 2, 3, 3, 2, 4, 1, 3, 3, 3, 2, 3, 3, 4, 3, 1~
$ YearsInCurrentRole  <int> 4, 7, 0, 7, 2, 7, 0, 0, 7, 7, 4, 5, 2, 2, 2, 9~
$ Attrition           <fct> Positive, Negative, Positive, Negative, Negati~
```

Aufgabe 4 (5+7 = 12 Punkte)

Aufgabe 4.1 (2+3 = 5 Punkte). Für die Variable `Attrition`, welche Beschreibt, ob ein Angestellter oder eine Angestellte das Unternehmen verlässt ("Positive") oder nicht ("Negative"), wird nun ein logistisches Regressionsmodell auf Trainingsdaten geschätzt. Folgende Übersicht über die Geschätzten Parameter resultiert aus diesem Modell:

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	2.86830	0.53585	5.353	8.66e-08	***
Age	a	0.01081	-5.244	1.57e-07	***
JobInvolvement	-0.52259	0.11899	-4.392	1.12e-05	***
JobSatisfaction	-0.28658	0.07830	-3.660	0.000252	***
YearsInCurrentRole	-0.11899	0.02965	b	5.98e-05	***

1. Berechne die fehlenden Werte *a* und *b*.
2. Wie verändern sich die Odds des Modells durch das Erhöhen der Variable `JobInvolvement` um eine Einheit unter der Annahme, dass alle anderen Variablen gleich bleiben?

Aufgabe 4.2 (3+4 = 7 Punkte). Für das Modell aus Aufgabe 4.1 werden nun auf Basis der Testdaten zwei Konfusions Matrizen erzeugt. Über den jeweiligen Matrizen steht der Schwellenwert, welcher zur Berechnung der Konfusionsmatrix verwendet wurde.

		Schwellenwert = 0.4		Schwellenwert = 0.17	
Truth	Positive	10	56	36	30
	Negative	7	295	90	212
		Positive Negative Prediction		Positive Negative Prediction	

1. Welcher der beiden Schwellenwerte sollte verwendet werden, um eine möglichst hohe Accuracy zu erreichen? Begründe die Aussage.
2. Welcher der beiden Schwellenwerte sollte gewählt werden, um eine möglichst hohe Spezifität bei der Erkennung von Mitarbeitenden zu erreichen, die das Unternehmen nicht verlassen möchten? Begründe die Aussage.

Aufgabe 5 (12 Punkte)

Aufgabe 5.1 (2+4+6 = 12 Punkte). Beim Datensatz `data_attrition_filtered_new` sollen nun auf die numerischen Variablen verschiedene Clusterverfahren angewendet werden.

1. Erkläre kurz in eigenen Worten den Unterschied zwischen dem Single- und Complete-Linkage Verfahren.
2. Folgend ist ein Auszug aus dem "merge"-Attribut eines hierarchischen Clustering-Objektes gegeben.

```
[468,] -549  146
[469,]  147  223
[470,]  -35 -110
```

Beschreibe für jeden der drei abgebildeten Schritte die folgende Punkte:

- i) Der wievielte Clusterschritt wurde durchgeführt?
 - ii) Welche Punkte bzw. Cluster wurden in dem entstprechen Schritt zusammengeführt.
3. Nachdem der k -Means Algorithmus auf die normalisierten Daten `data_attrition_filtered_new` mit $k = 2$ angewendet wurde, ergeben sich folgende Clusterzentren:

Variable	Zentrum ₁	Zentrum ₂
Age	2	-2
JobInvolvement	-1	0
JobSatisfaction	-3	0
YearsInCurrentRole	0	2

Für eine neue Mitarbeiterin seien folgende Daten gegeben:

Variable	Wert
Age	1
JobInvolvement	3
JobSatisfaction	2
YearsInCurrentRole	0

- i) Berechne den jeweiligen Abstand zu den Clusterzentren mittels der L^2 -Metrik.
- ii) Zu welchem der beiden Cluster würde die Mitarbeiterin hinzugefügt werden?