
Statistics & Finance with Excel

3. Auswertung von mehrdimensionalem Datenmaterial

Universität Augsburg
Lehrstuhl für Statistik
Prof. Dr. Yarema Okhrin

Diese Datei ist urheberrechtlich geschützt. Der Urheber stellt sie im Wintersemester 2022/23 ausschließlich denjenigen Studierenden der Universität Augsburg zur Verfügung, die für die jeweilige Veranstaltung bei Digicampus angemeldet sind. Jede Weitergabe und Vervielfältigung ist untersagt und wird als Urheberrechtsverletzung behandelt, die verfolgt wird. Es wird darauf hingewiesen, dass die Datei sichtbare oder unsichtbare Sicherheitsmerkmale aufweisen kann.

Grundsätzliches

- Beispiele zur Berechnung der vorgestellten Methoden und Größen sind jeweils in der entsprechenden Exceldatei zu finden.
- Literaturempfehlung zum Nachlesen:

Bamberg, G., Baur, F., Krapp, M.: Statistik, 17. Auflage, München 2012

- Kontingenztafel: Kapitel 4.1
- Korrelationsrechnung: Kapitel 4.2
- Regressionsrechnung (deskriptiv): Kapitel 4.3

Kontingenztafel (I)

- Aufbauend auf einer Urliste vom Umfang n zu 2 Merkmalen X und Y
 $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$
wird eine Kontingenztafel erstellt zur Darstellung mehrdimensionaler Häufigkeitsverteilungen.
- geeignet bei wenigen Ausprägungen bzw. klassierten Daten oder falls viele der n Wertepaare identisch sind.

Ausprägung des Merkmals X \ Ausprägung des Merkmals Y				
	b_1	b_2	$\dots$	b_l
a_1	n_{11}	n_{12}	$\dots$	n_{1l}
a_2	n_{21}	n_{22}	$\dots$	n_{2l}
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$
a_k	n_{k1}	n_{k2}	$\dots$	n_{kl}

Kontingenztafel (II)

- **Gemeinsame Häufigkeiten**

absolute Häufigkeit, mit der Wertepaar (a_i, b_j) in der Urliste vorkommt

$$n_{ij} = n(a_i, b_j)$$

- **Randhäufigkeiten**

Für $n_{i.}$ gilt: Anzahl der Merkmalsträger, die für das erste Merkmal die Ausprägung a_i aufweisen, unabhängig der Ausprägung des zweiten Merkmals b_j ($n_{.j}$ analog für zweites Merkmal)

$$n_{i.} = \sum_{j=1}^l n_{ij} \quad \text{und} \quad n_{.j} = \sum_{i=1}^k n_{ij}$$

Kontingenztafel (III)

- **Bedingte relative Häufigkeiten**

Dabei ist $h_1(a_i|b_j)$ die relative Häufigkeit, mit der a_i bei denjenigen Merkmalsträgern auftritt, die für das zweite Merkmal b_j aufweisen ($h_2(b_j|a_i)$ analog).

$$h_1(a_i|b_j) = \frac{n_{ij}}{n_{.j}} \quad \text{und} \quad h_2(b_j|a_i) = \frac{n_{ij}}{n_{i.}}$$

- **Unabhängigkeit**

Zwei Merkmale X, Y sind unabhängig, falls für **alle** i, j gilt:

$$n_{ij} = \frac{n_{i.} * n_{.j}}{n} = \tilde{n}_{ij}$$

- **Beispiel**

Es wurden 1000 Personen befragt, ob sie Produkt A oder B bevorzugen. Das Ergebnis wurde nach Geschlecht getrennt ausgewertet.

Beispiel Kontingenztafel

Es wurden 1000 Personen befragt, ob sie Produkt A oder B bevorzugen. Das Ergebnis wurde nach Geschlecht getrennt ausgewertet:

	Geschlecht (b_j)		
Produkt (a_i)	weiblich	männlich	Randhäufigkeit
Produkt A	240	560	800
Produkt B	60	140	200
Randhäufigkeit	300	700	1000

Überprüfung auf Unabhängigkeit:

$$\tilde{n}_{11} = \frac{800 * 300}{1000} = 240 = n_{11} \rightarrow \text{unabhängig}$$

Streuungsdiagramm (I)


- Sinnvoll bei vielen verschiedenen Ausprägungen
- Ablauf: alle (x_i, y_i) sowie $(\bar{x}, \bar{y})$ werden in Koordinatensystem eintragen
- in Excel: Registerkarte „Einfügen“ → Gruppe „Diagramme“ → **Punkt (XY)**

Beispiel (vgl. Bamberg, G., Baur, F., Krapp, M., Beispiel 4.4):

In einer Branche wurden $n = 15$ Unternehmen in Bezug auf den **Jahresgewinn** (X) und die **Jahresmiete für ihre EDV-Anlage** (Y) untersucht. Bei Vorhandensein einer unternehmenseigenen EDV-Anlage wurde die Jahresmiete aus dem Kaufpreis errechnet.

Unternehmen	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	Mittelwert
Gewinn [Mio. EUR]	10	15	15	20	20	25	30	30	30	35	35	40	45	50	50	30
Miete [Tsd. EUR]	30	30	100	50	100	80	50	100	250	180	330	200	400	500	600	200

Streuungsdiagramm (II)



Korrelationsrechnung

- Ziel: Quantifizierung der Interdependenz zweier Merkmale X und Y
- Die Wahl des Korrelationskoeffizienten hängt vom Skalenniveau von X und Y ab:

Skalierung von X \ Skalierung von Y			
	kardinal	ordinal	nominal
kardinal	Bravais-Pearson-Korrelationskoeffizient	↑	↑
ordinal	←	Rangkorrelationskoeffizient von Spearman	↑
nominal	←	←	Kontingenzkoeffizient

Bravais-Pearson-Korrelationskoeffizient (I)


- Voraussetzung: X und Y müssen kardinal skaliert sein.

$$r_{XY} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}}$$

- Eigenschaften
 - maßstabsunabhängig
 - es gilt: $-1 \leq r_{XY} \leq +1$
-  Excel: PEARSON(MATRIX1; MATRIX2)

Bravais-Pearson-Korrelationskoeffizient (II)

- Zusammenhang zwischen r_{XY} und der Form des Streudiagramms



Regressionsrechnung (I)

- Y interpretiert als Funktion von X : $y = f(x)$
- X ist der Regressor bzw. unabhängige Variable
- Y ist der Regressand bzw. abhängige Variable
- Im Falle der linearen Regression ist $f(x)$ eine Gerade

$$y = \beta_0 + \beta_1 x$$


mit β_0 als Achsenabschnitt und β_1 als Steigung der Gerade.

- Schätzung von β_0 und β_1 erfolgt meist nach dem „Prinzip der kleinsten Quadrate“ (KQ) durch Minimierung folgender Quadratsumme:

$$Q(\beta_0, \beta_1) = \sum_{i=1}^n [y_i - (\beta_0 + \beta_1 x_i)]^2$$

Regressionsrechnung (II)


- Zu beachten:
 - die durch die KQ-Methode geschätzten Werte für β_0 und β_1 werden als Regressionskoeffizienten $\hat{\beta}_0$ und $\hat{\beta}_1$ bezeichnet.
 - es ergibt sich die geschätzte Regressionsgrade: $y = \hat{\beta}_0 + \hat{\beta}_1 x$



Regressionsrechnung (III)

- in Excel:
 - **Schätzen der Regressionsgrade** gemäß folgendem Vorgehen:
 -  mit Hilfe von RGP(Y_WERTE; [X_WERTE]; [KONSTANTE]; [STATS]):
zwei nebeneinander liegende Zellen markieren, RGP()-Funktion eingeben
und mit Strg+Shift+Enter abschließen
 -  STEIGUNG(Y_WERTE; X_WERTE): berechnet nur $\hat{\beta}_1$
 -  ACHSENABSCHNITT(Y_WERTE; X_WERTE): berechnet nur $\hat{\beta}_0$
 - **Streuungsdiagramm** erstellen (Basis: Punkt (XY)-Diagramm):
Linksklick auf einen Datenpunkt → Rechtsklick → „Trendlinie hinzufügen“ →
„Trend linear“ auswählen → „Formel im Diagramm anzeigen“ auswählen und
„schließen“
- **Theoretische y-Werte** (=durch Regression erklärte Werte): $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$
 -  – in Excel: TREND(Y_Werte; [X_Werte]; [Neue_x_Werte]): Damit kann zu jedem x_i der
entsprechende theoretische y-Wert bestimmt werden → Prognose

Regressionsrechnung (IV) (Fortsetzung Beispiel F. 7)



Determinationskoeffizient (I)

- Ausgangspunkt: Wie gut beschreibt die Regressionsgrade den Zusammenhang von X und Y ?
- Die Differenzen zwischen den empirischen und den theoretischen y -Werten werden als Residuen bezeichnet: $\hat{u}_i = y_i - \hat{y}_i$
→ $Q(\beta_0, \beta_1) = \sum_{i=1}^n \hat{u}_i^2$ als Gütemaß ungeeignet, da nicht normiert
- Lösung: Determinationskoeffizient als Maß der Anpassungsgüte:

$$R^2 = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$




– in Excel: BESTIMMTHEITSMASS(Y_WERTE; X_WERTE)


Determinationskoeffizient (II)

- R^2 wird auch bezeichnet als ...
 - Bestimmtheitskoeffizient
 - quadrierter multipler Korrelationskoeffizient
 - durch die Regression erklärter Anteil der Varianz
- Eigenschaften von R^2
 - $R^2 = r^2$
 - $R^2 \in [0,1]$
 - $R^2 = 0$, falls X, Y unkorreliert
 - $R^2 = 1$, falls alle Punkte auf Regressionsgerade

Regressionsgerade



Determinationskoeffizient (II) (Fortsetzung Beispiel F. 7 u. 15)



In diesem Kapitel verwendete Excel-Funktionen



- Bravais-Pearson-Korrelationskoeffizient: PEARSON(MATRIX1; MATRIX2)
- Schätzen der Regressionsgrade:
RGP(Y_WERTE; [X_WERTE]; [KONSTANTE]; [STATS])
- Steigung der Regressionsgerade: STEIGUNG(Y_WERTE; X_WERTE)
- Achsenabschnitt der Regressionsgerade:
ACHSENABSCHNITT(Y_WERTE; X_WERTE)
- Zu jedem x_i der entsprechende theoretische y -Wert bestimmen: TREND()
- Determinationskoeffizient: BESTIMMTHEITSMASS(Y_WERTE; X_WERTE)